

Predição do Nível de Liquidez em Fundos de Investimento com uso de Machine Learning a partir de dados da ANBIMA

Bruna Sousa Valerio dos Santos¹, Danilo Ferreira Rocha², Fernanda de Moraes Brazolin³, Yasmin Reis Toledo⁴

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10418226@mackenzista.com.br, 10402374@mackenzista.com.br,
10417732@mackenzista.com.br, 10417375@mackenzista.com.br}

Resumo. Este trabalho tem como objetivo aplicar técnicas de Machine Learning para prever o nível de liquidez de fundos de investimento a partir de dados públicos disponibilizados pela ANBIMA. A liquidez foi definida com base no prazo de pagamento de resgate, que indica o tempo necessário para que o investidor receba seus recursos após solicitar o resgate. A metodologia adotada envolveu a análise exploratória dos dados, tratamento e preparação da base em Python, seguida da aplicação de um modelo de classificação utilizando o framework scikit-learn, especificamente o algoritmo Random Forest. O modelo foi treinado para classificar os fundos em três categorias de liquidez: alta, média e baixa. Os resultados obtidos indicam que o modelo apresenta desempenho satisfatório, com acurácia aproximada de 65%, sendo mais eficiente na identificação de fundos com alta liquidez. O estudo contribui para a utilização de técnicas de Inteligência Artificial no apoio à tomada de decisão no mercado financeiro.

Palavras-chave: Machine Learning; fundos de investimento; liquidez; classificação; ANBIMA.

Abstract. This study aims to apply Machine Learning techniques to predict the liquidity level of investment funds based on public data provided by ANBIMA. Liquidity was defined based on the redemption payment period, which represents the time required for investors to receive their funds after requesting redemption. The adopted methodology involved exploratory data analysis, data treatment and preparation using Python, followed by the application of a classification model using the scikit-learn framework, specifically the Random Forest algorithm. The model was trained to classify funds into three liquidity categories: high, medium, and low. The results indicate that the model achieves satisfactory performance, with an accuracy of approximately 65%, being more effective in identifying funds with high liquidity. This study contributes to the application of Artificial Intelligence techniques to support decision-making in the financial market.

Keywords: Machine Learning; investment funds; liquidity; classification; ANBIMA.

1. Introdução

a) Contextualização

A liquidez é um dos principais fatores considerados por investidores na escolha de fundos de investimento, pois está diretamente relacionada à disponibilidade dos recursos aplicados. Fundos com alta liquidez permitem resgates rápidos, enquanto fundos com baixa liquidez podem impor prazos maiores, impactando o acesso ao capital.

Com o crescimento do volume de dados no mercado financeiro, torna-se cada vez mais relevante o uso de técnicas computacionais para análise e previsão de comportamentos. Nesse contexto, a Inteligência Artificial, especialmente por meio de técnicas de Machine Learning (PEDREGOSA et al., 2011), surge como uma ferramenta poderosa para identificar padrões e auxiliar na tomada de decisão.

b) Justificativa

A análise manual da liquidez de fundos pode ser limitada, especialmente diante de grandes volumes de dados e múltiplas variáveis. Dessa forma, o uso de modelos de Machine Learning permite automatizar esse processo, oferecendo previsões mais rápidas e baseadas em padrões históricos.

Além disso, investidores muitas vezes não possuem conhecimento técnico suficiente para avaliar o risco de liquidez de forma estruturada, tornando relevante o desenvolvimento de soluções que simplifiquem essa análise.

c) Objetivo

O objetivo deste trabalho é desenvolver um modelo de Machine Learning capaz de classificar o nível de liquidez de fundos de investimento com base em suas características.

Como objetivos específicos:

- tratar e preparar a base de dados;
- realizar análise exploratória;
- construir um modelo de classificação;
- avaliar o desempenho do modelo;
- interpretar os resultados obtidos.

d) Opção do projeto

O projeto enquadra-se na **Opção Framework**, utilizando o framework *scikitlearn* para construção de um modelo de classificação de dados financeiros.

2. Descrição do Problema

O problema abordado neste trabalho consiste em prever o nível de liquidez de fundos de investimento a partir de suas características estruturais e operacionais.

No contexto do mercado financeiro, a liquidez representa um fator crítico na tomada de decisão dos investidores, uma vez que está diretamente relacionada ao tempo necessário para a conversão dos investimentos em recursos disponíveis. Entretanto, a avaliação desse aspecto nem sempre é trivial, sobretudo diante da grande quantidade de fundos disponíveis e da diversidade de suas características. Essa complexidade pode levar investidores a decisões inadequadas, como a aplicação em fundos com prazos de resgate incompatíveis com suas necessidades de liquidez.

Diante desse cenário, o problema foi modelado como uma tarefa de classificação supervisionada, na qual o objetivo é prever o nível de liquidez de um fundo com base em suas variáveis descritivas. Para tanto, definiu-se como variável alvo o prazo de pagamento de resgate, convertido em categorias representativas do nível de liquidez, conforme os seguintes critérios:

- **Alta liquidez:** prazo de resgate de até 4 dias;
- **Média liquidez:** prazo entre 5 e 30 dias;
- **Baixa liquidez:** prazo superior a 30 dias.

A solução proposta utiliza técnicas de Machine Learning para identificar padrões nos dados e automatizar a classificação dos fundos, contribuindo para uma análise mais rápida, objetiva e baseada em dados. Dessa forma, busca-se oferecer suporte à tomada de decisão no mercado financeiro, reduzindo a assimetria de informação e facilitando a avaliação do risco de liquidez por parte dos investidores.

3. Aspectos Éticos e Responsabilidade

O uso de Inteligência Artificial no contexto financeiro demanda especial atenção a aspectos éticos e à responsabilidade no desenvolvimento e aplicação das soluções propostas.

Um dos principais pontos de atenção refere-se ao viés presente nos dados, uma vez que modelos de Machine Learning aprendem padrões a partir de bases históricas. Caso essas bases apresentem distribuição desigual entre as classes como observado neste estudo, o modelo pode privilegiar categorias majoritárias, comprometendo a equidade das previsões e reduzindo a confiabilidade em cenários menos representados.

Outro aspecto relevante diz respeito à interpretação e ao uso dos resultados. As previsões geradas por modelos não devem ser utilizadas de forma isolada como base para decisões financeiras, pois estão sujeitas a incertezas e limitações inerentes ao processo de modelagem. Nesse sentido, torna-se essencial a atuação complementar de especialistas humanos, capazes de contextualizar e validar as recomendações geradas.

Adicionalmente, destaca-se a importância da transparência e explicabilidade dos modelos, especialmente em aplicações financeiras. A compreensão dos fatores que influenciam as previsões é fundamental para garantir confiança no sistema e permitir a identificação de possíveis inconsistências ou vieses.

Por fim, ressalta-se a responsabilidade dos desenvolvedores na validação, monitoramento e atualização contínua do modelo, assegurando que seu desempenho permaneça adequado ao longo do tempo e alinhado às mudanças do mercado.

4. Dataset e Análise Exploratória

O *dataset* utilizado neste trabalho é público e foi obtido a partir da base de dados disponibilizada pela Associação Brasileira das Entidades dos Mercados Financeiro e de Capitais (ANBIMA), contendo informações estruturais e operacionais sobre fundos de investimento no mercado brasileiro.

A base original possuía 50.553 registros e 28 variáveis, abrangendo informações referentes à estrutura dos fundos, categoria ANBIMA, composição, perfil do investidor, tributação, classificação, prazo de resgate e demais características operacionais. As variáveis apresentavam diferentes tipos de dados, incluindo dados categóricos (string), numéricos (int64 e float64) e temporais (datetime64), evidenciando a heterogeneidade do conjunto de dados e a necessidade de preparação prévia antes da aplicação do modelo de aprendizado de máquina.

Para o desenvolvimento do projeto, foram selecionadas 14 variáveis consideradas relevantes para a previsão do nível de liquidez, sendo elas: Categoria ANBIMA, Tipo ANBIMA, Composição do Fundo, Aberto Estatutariamente, Fundo ESG, Tributação Alvo, Tipo de Investidor, Característica do Investidor, Adaptado 175, Foco Atuação, Nível 1 Categoria, Nível 2 Categoria, Nível 3 Subcategoria e Prazo de Pagamento de Resgate em dias.

Tratamento e preparação dos dados

Inicialmente, foi realizada a remoção dos registros que não possuíam valor preenchido para a variável “Prazo Pagamento Resgate em dias”, utilizada como base para a construção da variável-alvo do modelo. Após essa etapa de limpeza, a base passou de 50.553 registros para 33.101 registros válidos, mantendo 15 variáveis utilizadas no projeto.

Além disso, foi realizada a conversão do prazo de resgate para formato numérico, eliminando inconsistências de preenchimento. Posteriormente, foi criada a variável-alvo denominada “Nível de Liquidez”, construída a partir do prazo de pagamento de resgate, conforme os seguintes critérios:

- Alta liquidez: prazo de resgate de até 4 dias;
- Média liquidez: prazo entre 5 e 30 dias;
- Baixa liquidez: prazo superior a 30 dias.

Também foram aplicadas técnicas de tratamento de dados faltantes por meio de imputação utilizando o valor mais frequente (moda), bem como a transformação das variáveis categóricas em formato numérico por meio da técnica OneHotEncoder, permitindo sua utilização pelo algoritmo de aprendizado supervisionado.

A análise dos dados também evidenciou a presença de valores ausentes em algumas variáveis da base original. Entre as mais relevantes, destacam-se “Código CVM Subclasse”, com aproximadamente 94,13% de valores ausentes, “Aplicação Inicial Mínima”, com 48,93%, e “Prazo Pagamento Resgate em dias”, com 34,52%, justificando a necessidade do tratamento prévio dos dados antes da modelagem.

Análise exploratória dos dados

Em relação ao prazo de pagamento de resgate, observou-se elevada heterogeneidade entre os fundos analisados. A variável apresentou média de 18,35 dias, mediana de 3 dias, desvio padrão de 54,42 dias e valor máximo de 1.901 dias, indicando forte dispersão dos dados e presença de valores extremos.

Conforme demonstrado na Figura 1, verifica-se predominância de fundos classificados como de alta liquidez, representando 18.731 registros (56,59%), enquanto os fundos de baixa liquidez corresponderam a 7.472 registros (22,57%) e os de média liquidez totalizaram 6.898 registros (20,84%). Os resultados indicam a existência de um desbalanceamento moderado entre as classes, sem, contudo, comprometer significativamente o treinamento do modelo.




Figura 1 – Distribuição dos fundos por nível de liquidez.

Fonte: elaborado pelos autores (2026).

No que se refere ao prazo de pagamento de resgate, a distribuição apresentada na Figura 2 evidencia forte concentração dos fundos em prazos reduzidos, principalmente próximos a zero e poucos dias de resgate. Entretanto, observa-se também a presença de fundos com prazos significativamente superiores, o que contribui para uma distribuição assimétrica à direita e demonstra a coexistência de fundos com elevada e baixa liquidez no mercado.




Figura 2 – Distribuição do prazo de pagamento de resgate dos fundos de investimento.
Fonte: elaborado pelos autores (2026).

Quanto às categorias dos fundos, verificou-se predominância significativa de fundos classificados como Multimercados (15.048 registros), seguidos por Renda Fixa (6.128), Ações (5.223) e Previdência (4.953). Tal comportamento sugere maior representatividade dessas categorias dentro da amostra analisada.

Conforme apresentado na Figura 3, as categorias FIDC, ETF, Cambial, FII, FIP e FIAGRO aparecem em menor proporção na base de dados.




Figura 3 – Top 10 categorias ANBIMA mais frequentes na base de dados.
Fonte: elaborado pelos autores (2026).

5. Metodologia

A metodologia adotada neste trabalho baseia-se em técnicas de Machine Learning supervisionado, com o objetivo de classificar o nível de liquidez de fundos de investimento a partir de suas características estruturais e operacionais.

Para a construção do modelo preditivo, foi utilizado o algoritmo Random Forest *Classifier*, implementado por meio da biblioteca *scikit-learn*, sendo escolhido devido à sua robustez, capacidade de lidar com grande volume de variáveis categóricas após transformação e eficiência na identificação de relações não lineares entre os atributos da base de dados.

A etapa de pré-processamento envolveu inicialmente a seleção das variáveis consideradas relevantes para a tarefa de classificação, incluindo informações relacionadas à categoria do fundo, composição, perfil do investidor, tributação, estrutura estatutária e classificação ANBIMA.

Posteriormente, foram aplicadas técnicas de preparação dos dados, incluindo o tratamento de valores ausentes por meio de imputação utilizando o valor mais frequente (moda), reduzindo perdas de informação e permitindo maior consistência dos dados utilizados no treinamento do modelo.

As variáveis categóricas foram convertidas para formato numérico utilizando o método *OneHotEncoder*, permitindo sua interpretação pelo algoritmo de aprendizado de máquina. Esse procedimento possibilitou a representação das diferentes categorias existentes na base sem introduzir relações ordinais artificiais entre elas.

A variável-alvo foi construída a partir do Prazo de Pagamento de Resgate em dias, sendo categorizada em três níveis de liquidez:

- **Alta liquidez:** prazo de resgate de até 4 dias;
- **Média liquidez:** prazo entre 5 e 30 dias;
- **Baixa liquidez:** prazo superior a 30 dias.

Após o pré-processamento, a base foi dividida em dois subconjuntos: 80% dos dados destinados ao treinamento do modelo e 20% reservados para teste, permitindo avaliar a capacidade de generalização da solução em dados não utilizados durante o treinamento.

Considerando o desbalanceamento moderado entre as classes identificado na análise exploratória, foram realizados ajustes nos hiperparâmetros do modelo com o objetivo de reduzir possíveis vieses de classificação e melhorar sua capacidade preditiva. Para isso, foram utilizados os seguintes parâmetros no algoritmo Random Forest:

- Número de árvores (*n_estimators*): 400;
- Profundidade máxima (*max_depth*): 20;
- Número mínimo de amostras para divisão (*min_samples_split*): 5;
- Número mínimo de amostras por folha (*min_samples_leaf*): 2;

- Balanceamento de classes (class_weight): "balanced";
- Semente de reprodutibilidade (random_state): 42.

Por fim, o desempenho do modelo foi avaliado utilizando métricas de classificação, incluindo acurácia, precision, recall, F1-score e matriz de confusão, permitindo analisar não apenas o desempenho geral do modelo, mas também sua capacidade de identificar corretamente cada categoria de liquidez.

6. Resultados

A aplicação do modelo de Random Forest Classifier permitiu a construção de uma solução preditiva voltada à classificação do nível de liquidez dos fundos de investimento com base em suas características estruturais e operacionais.

Para avaliação do desempenho do modelo, a base de dados foi dividida em conjuntos de treinamento (80%) e teste (20%), totalizando 26.480 registros utilizados no treinamento e 6.621 registros reservados para validação do modelo.

O modelo apresentou acurácia de 65,72%, indicando desempenho satisfatório na tarefa de classificação proposta, especialmente considerando a heterogeneidade dos dados financeiros analisados e a predominância moderada de uma das classes de liquidez.

Além da acurácia, foram utilizadas métricas complementares para avaliar o desempenho do modelo em cada categoria de liquidez, incluindo precision, recall e F1-score.

Observou-se melhor desempenho do modelo na identificação de fundos classificados como alta liquidez, categoria que apresentou precision de 0,84, recall de 0,67 e F1-score de 0,75. Tal comportamento pode estar relacionado à maior representatividade dessa categoria na base de dados, fator que contribui para maior capacidade de aprendizado do algoritmo.

Por outro lado, os fundos classificados como média liquidez apresentaram desempenho inferior, com precision de 0,46, recall de 0,63 e F1-score de 0,53, indicando maior dificuldade do modelo em distinguir corretamente essa categoria. Os fundos de baixa liquidez obtiveram desempenho intermediário, apresentando precision de 0,56, recall de 0,64 e F1-score de 0,60.

A análise dos resultados sugere que existe maior proximidade entre os padrões associados às classes de média e baixa liquidez, o que pode dificultar sua diferenciação pelo algoritmo.

A matriz de confusão, apresentada na Figura 4, permite analisar detalhadamente os acertos e erros do modelo.




Figura 4 – Matriz de confusão da classificação do nível de liquidez dos fundos de investimento.
Fonte: elaborado pelos autores (2026).

Conforme demonstrado na Figura 4, observa-se que o modelo apresentou maior capacidade de acerto na classe Alta Liquidez, classificando corretamente 2.517 fundos dessa categoria. Para a classe Baixa Liquidez, o modelo acertou 959 classificações, enquanto 875 fundos de Média Liquidez foram corretamente identificados.

Também foi possível observar erros de classificação relevantes entre as categorias Média e Baixa Liquidez, sugerindo sobreposição de padrões entre essas classes e indicando um possível desafio inerente à estrutura dos dados analisados.

Adicionalmente, foi realizada a análise de importância das variáveis, com o objetivo de identificar quais atributos exerceram maior influência sobre as previsões realizadas pelo modelo.




Figura 5 – Top 15 variáveis mais importantes utilizadas pelo modelo Random Forest.
Fonte: elaborado pelos autores (2026).

Os resultados apresentados na Figura 5 evidenciam que variáveis relacionadas à estrutura estatutária do fundo, perfil do investidor, composição do fundo, tributação alvo e subcategoria ANBIMA exerceram maior influência sobre a previsão do nível de liquidez.

Entre os fatores de maior relevância destacam-se as variáveis “Aberto Estatutariamente”, “Característica do Investidor”, “Tipo de Investidor Exclusivo”, “Composição do Fundo” e “Tributação Alvo”, sugerindo que aspectos regulatórios, estruturais e do público-alvo do fundo possuem relação significativa com o prazo de pagamento de resgate.

De maneira geral, os resultados obtidos demonstram que o modelo foi capaz de identificar padrões relevantes na base de dados, alcançando desempenho satisfatório para a tarefa proposta e evidenciando o potencial de técnicas de Inteligência Artificial para apoio à análise de liquidez de fundos de investimento.

7. Conclusão

O presente trabalho teve como objetivo desenvolver um modelo de Machine Learning capaz de classificar o nível de liquidez de fundos de investimento a partir de características estruturais e operacionais disponibilizadas pela base pública da ANBIMA. Para isso, foram empregadas técnicas de preparação e análise exploratória de dados, bem como a aplicação de um algoritmo supervisionado de classificação, utilizando o framework scikit-learn e o modelo Random Forest Classifier.

Os resultados obtidos demonstraram que o modelo foi capaz de identificar padrões relevantes associados ao nível de liquidez dos fundos de investimento, alcançando acurácia de 65,72%, valor considerado satisfatório diante da heterogeneidade da base analisada e da complexidade do mercado financeiro. Observou-se melhor desempenho na identificação de fundos classificados como alta liquidez, enquanto as categorias de média

e baixa liquidez apresentaram maior dificuldade de diferenciação, evidenciando possível sobreposição entre seus padrões de comportamento.

A análise exploratória realizada permitiu compreender melhor a composição da base de dados, identificando a predominância de determinadas categorias de fundos, a existência de valores ausentes relevantes e um desbalanceamento moderado entre as classes, fatores que influenciam diretamente o desempenho do modelo preditivo. Adicionalmente, a análise de importância das variáveis evidenciou que aspectos relacionados à estrutura estatutária do fundo, perfil do investidor, composição do fundo e tributação alvo exerceram influência significativa na classificação do nível de liquidez.

Dessa forma, considera-se que os resultados esperados foram alcançados, uma vez que foi possível construir e validar um modelo de classificação funcional, capaz de prever o nível de liquidez dos fundos com desempenho consistente e interpretável. O projeto também permitiu aplicar, de forma prática, conceitos estudados na disciplina de Inteligência Artificial, incluindo pré-processamento de dados, análise exploratória, classificação supervisionada, ajuste de hiperparâmetros e avaliação de desempenho de modelos.

Como limitações do estudo, destacam-se a dependência de dados públicos disponibilizados pela ANBIMA, a existência de valores ausentes em variáveis relevantes e a dificuldade do modelo em diferenciar algumas categorias de liquidez. Como trabalhos futuros, sugere-se a exploração de outros algoritmos de aprendizado de máquina, como XGBoost, Gradient Boosting e Redes Neurais, bem como a inclusão de novas variáveis financeiras que possam ampliar a capacidade preditiva da solução.

8. Link

Link do repositório do github: <https://github.com/bruvalerio/Projeto-IA>

Link vídeo Youtube: <https://youtu.be/d5aEIR-RvrI?si=ukcKgU0kbKjZab3f>

9. Referências bibliográficas

ASSOCIAÇÃO BRASILEIRA DAS ENTIDADES DOS MERCADOS FINANCEIRO E DE CAPITALIS. **Base de dados de fundos de investimento**. Disponível em: <https://data.anbima.com.br/datasets>. Acesso em: 22 mar. 2026.

BREIMAN, L. **Random Forests**. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001. Disponível em: <https://link.springer.com/article/10.1023/A:1010933404324>. Acesso em: 19 maio 2026.

GÉRON, A. **Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow**. 3. ed. Sebastopol: O'Reilly Media, 2022.

HUNTER, J. D. **Matplotlib: A 2D Graphics Environment**. *Computing in Science & Engineering*, v. 9, n. 3, p. 90–95, 2007. Disponível em: <https://matplotlib.org/stable/>. Acesso em: 22 mar. 2026.

MCKINNEY, W. **Data Structures for Statistical Computing in Python**. In: *Proceedings of the 9th Python in Science Conference*, 2010. Disponível em: <https://pandas.pydata.org/docs/>. Acesso em: 22 mar. 2026.

PEDREGOSA, F. et al. **Scikit-learn: Machine Learning in Python**. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Disponível em: <https://scikit-learn.org/stable/>. Acesso em: 22 mar. 2026.

RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. 4. ed. Harlow: Pearson, 2021.

TAN, P.; STEINBACH, M.; KUMAR, V. **Introduction to Data Mining**. 2. ed. Boston: Pearson, 2019.

WITTEN, I. H.; FRANK, E.; HALL, M. A.; PAL, C. J. **Data Mining: Practical Machine Learning Tools and Techniques**. 4. ed. Burlington: Morgan Kaufmann, 2016.