Predição do Nível de Liquidez em Fundos de Investimento com uso de Machine Learning a partir de dados da ANBIMA

Bruna Sousa Valerio dos Santos [1], Danilo Ferreira Rocha[2], Fernanda de Moraes Brazolin[3], Yasmin Reis Toledo [4]

[1]Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10418226@mackenzista.com.br, 10402374@mackenzista.com.br, 10417732@mackenzista.com.br, 10417375@mackenzista.com.br}

Resumo. *Este trabalho tem como objetivo aplicar técnicas de Machine Learning para prever o nível de liquidez de fundos de investimento a partir de dados públicos disponibilizados pela ANBIMA. A liquidez foi definida com base no prazo de pagamento de resgate, que indica o tempo necessário para que o investidor receba seus recursos após solicitar o resgate. A metodologia adotada envolveu a análise exploratória dos dados, tratamento e preparação da base em Python, seguida da aplicação de um modelo de classificação utilizando o framework scikit-learn, especificamente o algoritmo Random Forest. O modelo foi treinado para classificar os fundos em três categorias de liquidez: alta, média e baixa. Os resultados obtidos indicam que o modelo apresenta desempenho satisfatório, com acurácia aproximada de 65%, sendo mais eficiente na identificação de fundos com alta liquidez. O estudo contribui para a utilização de técnicas de Inteligência Artificial no apoio à tomada de decisão no mercado financeiro.*

Palavras-chave: *Machine Learning; fundos de investimento; liquidez; classificação; ANBIMA.*

Abstract. *This study aims to apply Machine Learning techniques to predict the liquidity level of investment funds based on public data provided by ANBIMA. Liquidity was defined based on the redemption payment period, which represents the time required for investors to receive their funds after requesting redemption. The adopted methodology involved exploratory data analysis, data treatment and preparation using Python, followed by the application of a classification model using the scikit-learn framework, specifically the Random Forest algorithm. The model was trained to classify funds into three liquidity categories: high, medium, and low. The results indicate that the model achieves satisfactory performance, with an accuracy of approximately 65%, being more effective in identifying funds with high liquidity. This study contributes to the application of Artificial Intelligence techniques to support decision-making in the financial market.*

Keywords: *Machine Learning; investment funds; liquidity; classification; ANBIMA.*

1. Introdução

a) Contextualização

A liquidez é um dos principais fatores considerados por investidores na escolha de fundos de investimento, pois está diretamente relacionada à disponibilidade dos recursos aplicados. Fundos com alta liquidez permitem resgates rápidos, enquanto fundos com baixa liquidez podem impor prazos maiores, impactando o acesso ao capital.

Com o crescimento do volume de dados no mercado financeiro, torna-se cada vez mais relevante o uso de técnicas computacionais para análise e previsão de comportamentos. Nesse contexto, a Inteligência Artificial, especialmente por meio de técnicas de Machine Learning, surge como uma ferramenta poderosa para identificar padrões e auxiliar na tomada de decisão.

b) Justificativa

A análise manual da liquidez de fundos pode ser limitada, especialmente diante de grandes volumes de dados e múltiplas variáveis. Dessa forma, o uso de modelos de

Machine Learning permite automatizar esse processo, oferecendo previsões mais rápidas e baseadas em padrões históricos.

Além disso, investidores muitas vezes não possuem conhecimento técnico suficiente para avaliar o risco de liquidez de forma estruturada, tornando relevante o desenvolvimento de soluções que simplifiquem essa análise.

c) Objetivo

O objetivo deste trabalho é desenvolver um modelo de Machine Learning capaz de classificar o nível de liquidez de fundos de investimento com base em suas características.

Como objetivos específicos:

- tratar e preparar a base de dados;
- realizar análise exploratória;
- construir um modelo de classificação;
- avaliar o desempenho do modelo;
- interpretar os resultados obtidos.

d) Opção do projeto

O projeto enquadra-se na **Opção Framework**, utilizando o framework ***scikit-learn*** para construção de um modelo de classificação de dados financeiros.

2. Descrição do Problema

O problema abordado neste trabalho consiste em prever o nível de liquidez de fundos de investimento a partir de suas características estruturais e operacionais.

No contexto do mercado financeiro, a liquidez representa um fator crítico na tomada de decisão dos investidores, uma vez que está diretamente relacionada ao tempo necessário para a conversão dos investimentos em recursos disponíveis. Entretanto, a avaliação desse aspecto nem sempre é trivial, sobretudo diante da grande quantidade de fundos disponíveis e da diversidade de suas características. Essa complexidade pode levar investidores a decisões inadequadas, como a aplicação em fundos com prazos de resgate incompatíveis com suas necessidades de liquidez.

Diante desse cenário, o problema foi modelado como uma tarefa de classificação supervisionada, na qual o objetivo é prever o nível de liquidez de um fundo com base em suas variáveis descritivas. Para tanto, definiu-se como variável alvo o prazo de pagamento

de resgate, convertido em categorias representativas do nível de liquidez, conforme os seguintes critérios:

- **Alta liquidez:** prazo de resgate de até 4 dias;
- **Média liquidez:** prazo entre 5 e 30 dias;
- **Baixa liquidez:** prazo superior a 30 dias.

A solução proposta utiliza técnicas de Machine Learning para identificar padrões nos dados e automatizar a classificação dos fundos, contribuindo para uma análise mais rápida, objetiva e baseada em dados. Dessa forma, busca-se oferecer suporte à tomada de decisão no mercado financeiro, reduzindo a assimetria de informação e facilitando a avaliação do risco de liquidez por parte dos investidores.

3. Aspectos Éticos e Responsabilidade

O uso de Inteligência Artificial no contexto financeiro demanda especial atenção a aspectos éticos e à responsabilidade no desenvolvimento e aplicação das soluções propostas.

Um dos principais pontos de atenção refere-se ao viés presente nos dados, uma vez que modelos de Machine Learning aprendem padrões a partir de bases históricas. Caso essas bases apresentem distribuição desigual entre as classes como observado neste estudo, o modelo pode privilegiar categorias majoritárias, comprometendo a equidade das previsões e reduzindo a confiabilidade em cenários menos representados.

Outro aspecto relevante diz respeito à interpretação e ao uso dos resultados. As previsões geradas por modelos não devem ser utilizadas de forma isolada como base para decisões financeiras, pois estão sujeitas a incertezas e limitações inerentes ao processo de modelagem. Nesse sentido, torna-se essencial a atuação complementar de especialistas humanos, capazes de contextualizar e validar as recomendações geradas.

Adicionalmente, destaca-se a importância da transparência e explicabilidade dos modelos, especialmente em aplicações financeiras. A compreensão dos fatores que influenciam as previsões é fundamental para garantir confiança no sistema e permitir a identificação de possíveis inconsistências ou vieses.

Por fim, ressalta-se a responsabilidade dos desenvolvedores na validação, monitoramento e atualização contínua do modelo, assegurando que seu desempenho permaneça adequado ao longo do tempo e alinhado às mudanças do mercado.

4. Dataset e Análise Exploratória

O dataset utilizado é público e foi obtido a partir da base de dados da ANBIMA.

A base contém informações sobre fundos de investimento, incluindo:

- categoria ANBIMA;
- tipo de fundo;
- composição;
- perfil de investidor;
- tributação;
- prazo de pagamento de resgate.

Tratamento dos dados

Foram realizadas as seguintes etapas:

- seleção das variáveis relevantes;
- remoção de valores nulos;
- conversão de dados para formato numérico;
- criação da variável alvo (nível de liquidez).

Análise exploratória

A análise indicou que:

- a maioria dos fundos apresenta alta liquidez;
- há desbalanceamento entre as classes;
- existem diferenças relevantes entre categorias.

5. Metodologia e Resultados Esperados

A metodologia adotada neste trabalho baseia-se em técnicas de Machine Learning supervisionado, com o objetivo de classificar o nível de liquidez dos fundos de investimento a partir de suas características. Para a construção do modelo preditivo, foi utilizado o algoritmo *Random Forest Classifier*, implementado por meio da biblioteca

scikit-learn, escolhido por sua robustez, capacidade de lidar com dados categóricos após transformação e eficiência na identificação de relações não lineares entre as variáveis.

A etapa de pré-processamento dos dados envolveu o tratamento de valores ausentes por meio de imputação utilizando o valor mais frequente, bem como a transformação das variáveis categóricas em formato numérico por meio do método *OneHotEncoder*. Essas etapas foram fundamentais para garantir a qualidade da base de dados e sua adequação ao modelo de aprendizado de máquina. A variável alvo foi definida a partir do prazo de pagamento de resgate, sendo categorizada em três níveis de liquidez (alta, média e baixa), conforme critérios previamente estabelecidos.

A base de dados foi dividida em dois subconjuntos, sendo 80% destinada ao treinamento do modelo e 20% reservada para teste, permitindo avaliar a capacidade de generalização da solução em dados não utilizados durante o treinamento. Essa abordagem contribui para uma avaliação mais confiável do desempenho do modelo.

Destaca-se que a base de dados apresenta desbalanceamento entre as classes, com predominância de fundos de alta liquidez, fator que impacta diretamente o desempenho do modelo. Foram realizados ajustes nos hiperparâmetros do modelo, incluindo o aumento do número de árvores e a utilização de balanceamento de classes, com o objetivo de melhorar a capacidade de generalização e reduzir o viés em relação à classe majoritária.

Os resultados obtidos até o momento indicam que o modelo apresentou acurácia aproximada de 65%, o que demonstra desempenho satisfatório para a tarefa proposta. Observou-se melhor desempenho na identificação de fundos com alta liquidez, classe majoritária da base de dados, enquanto as classes de média e baixa liquidez apresentaram desempenho moderado. Após ajustes nos parâmetros do modelo, verificou-se uma melhora no equilíbrio entre as classes, evidenciando um *trade-off* entre desempenho geral e capacidade de classificação mais equilibrada.

Dessa forma, espera-se que o modelo seja capaz de identificar automaticamente o nível de liquidez dos fundos de investimento, auxiliando investidores na análise de risco e contribuindo para decisões mais informadas.

6. Referências bibliográficas

ASSOCIAÇÃO BRASILEIRA DAS ENTIDADES DOS MERCADOS FINANCEIRO E DE CAPITAIS. Base de dados de fundos de investimento. Disponível em: https://data.anbima.com.br/datasets. Acesso em: 22 mar. 2026.

HUNTER, J. D. Matplotlib: A 2D Graphics Environment. *Computing in Science & Engineering*, v. 9, n. 3, p. 90–95, 2007. Disponível em: https://matplotlib.org/stable/ . Acesso em: 22 mar. 2026.

MCKINNEY, W. Data Structures for Statistical Computing in Python. In: *Proceedings of the 9th Python in Science Conference*, 2010. Disponível em: https://pandas.pydata.org/docs/. Acesso em: 22 mar. 2026.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Disponível em: https://scikit-learn.org/stable/. Acesso em: 22 mar. 2026.

Link repositório GitHub: https://github.com/bruvalerio/Projeto-IA